

Analisis Klasifikasi Multikelas Obesitas Menggunakan Algoritma Decision Tree Classifier, Random Forest Classifier, dan Support Vector Classifier (SVC)

Oon Septa¹, Novita Triyasri², Maharani Aulia Permata³, Aghitsna Salsabila⁴, Fahri Firdani⁵

¹Program Studi Matematika, Universitas Bengkulu, Bengkulu, Indonesia
^{2,3,4,5}Program Studi Sains Data, Institut Informatika dan Bisnis Darmajaya, Bandar Lampung, Indonesia
¹osepta@unib.ac.id, ²novitatriyasri@gmail.com, ³2411080012.2411080012@mail.darmajaya.ac.id, ⁴aghitsna.2411080001@mail.darmajaya.ac.id, ⁵fahrifirdani17@gmail.com



Article History:

Received: 02-02-2026
Revised : 03-03-2026
Accepted: 12-04-2026
Online : 14-04-2026



This is an open access article under the [CC-BY-SA](https://creativecommons.org/licenses/by-sa/4.0/) license

ABSTRAK

Obesitas masih menjadi salah satu tantangan kesehatan global yang signifikan, sehingga upaya klasifikasi dan deteksi dini sangat diperlukan untuk meminimalkan risiko penyakit degeneratif yang lebih serius. Penelitian ini membandingkan tiga algoritma machine learning Random Forest, Decision Tree, dan Support Vector Classifier (SVC) untuk melihat model mana yang paling efektif dalam memprediksi kategori status berat badan dan risiko obesitas. Dataset yang digunakan mencakup fitur fisik seperti usia, tinggi badan, berat badan, serta indeks massa tubuh (BMI). Proses penelitian mencakup tahapan pra-pemrosesan data, analisis korelasi fitur, pembagian data uji, pelatihan model, dan evaluasi menggunakan berbagai metrik performa. Hasil penelitian menunjukkan bahwa Random Forest memiliki kemampuan diskriminatif paling tinggi dengan nilai AUC 0.99, yang menunjukkan akurasi sempurna dalam membedakan antar kategori obesitas. Decision Tree memberikan hasil yang identik dalam hal akurasi sebesar 95,45%, namun dengan nilai AUC sedikit di bawah yaitu 0.96. Sementara itu, SVC memberikan hasil yang kompetitif dengan akurasi 81,82%, meskipun performanya berada di bawah kedua model berbasis pohon tersebut. Secara keseluruhan, penelitian ini memperlihatkan bahwa metode ensemble seperti Random Forest sangat potensial untuk digunakan sebagai pendukung keputusan dalam mendeteksi dan mengklasifikasikan status obesitas secara lebih akurat dan andal.

Kata Kunci: Obesitas, Machine Learning, Decision Tree, Random Forest, & SVC Klasifikasi Multikelas

ABSTRACT

Obesity remains a significant global health challenge, making early classification and detection essential to minimize the risk of more serious degenerative diseases. This study compares three machine learning algorithms—Random Forest, Decision Tree, and Support Vector Classifier (SVC) to determine which model is most effective in predicting weight status categories and obesity risks. The dataset used includes physical features such as age, height, weight, and Body Mass Index (BMI). The research process encompasses data preprocessing stages, feature correlation analysis, data splitting, model training, and evaluation using various performance metrics. The research results indicate that Random Forest demonstrates the highest discriminative ability with an AUC of 0.99, showing perfect accuracy in distinguishing between obesity categories. Decision Tree provides identical results in terms of accuracy at 95.45%, but with a slightly lower AUC value of 0.96. Meanwhile, SVC yields competitive results with an accuracy of 81.82%, although its performance remains below the two tree-based models. Overall, this study demonstrates that ensemble methods such as Random Forest hold great potential for use as decision support systems in detecting and classifying obesity status more accurately and reliably.

Keywords: Obesity, Machine Learning, Decision Tree, Random Forest, & SVC Multiclass Classification

1. PENDAHULUAN

Perkembangan teknologi informasi mempercepat akses layanan, namun memicu pola hidup sedentary yang berkontribusi pada lonjakan kasus obesitas remaja akibat minimnya aktivitas fisik dan tingginya konsumsi makanan olahan [1]. Obesitas terjadi akibat ketidakseimbangan antara asupan energi dan pengeluaran kalori dalam jangka panjang, yang dipengaruhi oleh pola makan, kualitas tidur,


hingga faktor genetic [2]. Mengingat dampaknya yang bersifat jangka panjang, penyuluhan dan deteksi dini menjadi urgensi utama untuk menekan risiko penyakit kronis di masa depan [3]. Selain gaya hidup, faktor psikologis serta lingkungan yang mempermudah akses makanan cepat saji turut memperparah kondisi ini [4]. Meskipun intervensi farmakologi dapat dipertimbangkan pada kondisi medis tertentu, perubahan gaya hidup tetap menjadi pilar utama dalam penanganan obesitas [5].

Namun, penanganan obesitas saat ini memerlukan pendekatan preventif yang lebih personal melalui pemanfaatan analisis data besar. Implementasi kecerdasan buatan dalam sektor kesehatan telah terbukti mampu mengidentifikasi korelasi faktor risiko yang kompleks secara lebih akurat [6]. Penerapan teknik klasifikasi data memungkinkan praktisi kesehatan untuk memetakan kategori berat badan berdasarkan variabel perilaku dan demografi secara efisien [7]. Oleh karena itu, transformasi data klinis ke dalam model komputasi menjadi solusi krusial dalam mendukung sistem pendukung keputusan medis [8]. Melalui pendekatan machine learning, intervensi dini dapat dilakukan secara tepat sasaran sebelum kondisi berkembang menjadi komorbiditas yang lebih serius [9]. Di sisi lain, pemilihan algoritma yang tepat sangat menentukan tingkat kepercayaan hasil prediksi dalam skenario klinis nyata [10].

Penelitian ini bertujuan membandingkan performa algoritma Decision Tree dan Random Forest dengan teknik hyperparameter tuning untuk memprediksi status obesitas. Kinerja model dievaluasi melalui metrik akurasi, presisi, recall, F1-Score, dan AUC guna menentukan model terbaik. Hasil penelitian ini diharapkan menjadi referensi dalam pengembangan sistem deteksi dini berbasis machine learning yang akurat dan efisien untuk mendukung upaya preventif di sektor kesehatan.

2. METODE

Penelitian ini menggunakan tools Python sebagai alat untuk membandingkan algoritma Decision Tree, Random Forest, dan Support Vector Classifier (SVC) dalam memprediksi status obesitas. Metode penelitian dilakukan melalui beberapa tahapan, yaitu pengumpulan data, pra-pemrosesan data, pembagian data menjadi data latih dan data uji, pemodelan menggunakan algoritma Decision Tree, Random Forest, dan Support Vector Classifier (SVC), serta evaluasi kinerja model. Alur proses penelitian ini dapat dilihat pada Gambar 1.




Gambar 1. Proses Penelitian

2.1. Pengumpulan Data

Tahap awal dalam penelitian ini adalah pengumpulan data yang diperoleh dari platform Kaggle, yaitu *Obesity Classification Dataset*. Dataset ini digunakan sebagai sumber data utama dalam proses analisis dan pemodelan untuk mengklasifikasikan status obesitas. Data yang digunakan berisi sejumlah data individu dengan berbagai atribut yang berkaitan dengan kondisi tubuh dan gaya hidup. Fitur-fitur yang terdapat dalam dataset ini mencerminkan karakteristik individu, seperti informasi demografis serta variabel yang berhubungan dengan kondisi fisik dan kebiasaan hidup yang dapat memengaruhi terjadinya obesitas. Status obesitas pada dataset ini digunakan sebagai label atau target yang menjadi acuan dalam proses klasifikasi menggunakan algoritma machine learning. Dataset yang telah dikumpulkan ini selanjutnya digunakan sebagai dasar dalam pengembangan model prediksi obesitas dengan algoritma Decision Tree dan Random Forest. Sebelum masuk ke tahap pemodelan, data akan melalui proses pra-pemrosesan untuk memastikan kualitas data yang digunakan sesuai dan layak untuk dianalisis lebih lanjut.

2.2. Pra-pemrosesan Data

Pra-pemrosesan data merupakan tahap awal yang penting dalam penelitian berbasis pembelajaran mesin karena bertujuan untuk menyiapkan data agar dapat digunakan secara optimal pada proses analisis dan pemodelan. Tahap ini dilakukan untuk memastikan kualitas data yang digunakan sehingga hasil klasifikasi yang dihasilkan menjadi lebih akurat dan reliabel, karena data yang tidak lengkap atau tidak konsisten dapat mempengaruhi validitas hasil penelitian [11]. Secara umum, tahapan pra-pemrosesan data meliputi pemeriksaan data, penanganan nilai yang hilang, penghapusan data duplikat, serta penyesuaian format data agar sesuai dengan kebutuhan algoritma klasifikasi yang digunakan [12]. Tahapan ini dilakukan sebelum proses pelatihan dan pengujian model untuk memastikan bahwa data yang digunakan telah siap dan sesuai dengan tujuan penelitian. Untuk lebih lanjut, dapat dilihat pada gambar berikut.



Gambar 2. Tahapan Pra-Pemrosesan Data

2.3 Pembagian Data

Tahap pembagian data dilakukan untuk memisahkan dataset ke dalam beberapa bagian yang memiliki fungsi berbeda dalam proses pemodelan machine learning. Pembagian ini bertujuan untuk menguji kemampuan model dalam melakukan prediksi pada data yang belum pernah digunakan selama proses pelatihan, sehingga hasil evaluasi yang diperoleh menjadi lebih objektif. Pada penelitian ini, dataset dibagi menjadi dua bagian, yaitu data latih dan data uji. Sebanyak 80% dari keseluruhan data digunakan sebagai data latih untuk membangun model, sementara 20% sisanya digunakan sebagai data uji untuk mengevaluasi kinerja model. Pembagian ini menghasilkan 86 data latih dan 22 data uji yang digunakan dalam proses penelitian.

2.4 Model

Dalam penelitian ini digunakan tiga algoritma *machine learning*, yaitu Decision Tree Classifier, Random Forest Classifier, dan Support Vector Classifier (SVC). Ketiga algoritma tersebut dipilih karena mampu menangani data dengan karakteristik yang beragam serta efektif digunakan pada permasalahan klasifikasi, khususnya di bidang kesehatan. Decision Tree dan Random Forest bekerja dengan membentuk struktur pohon keputusan untuk mempelajari pola dalam data, sedangkan SVC merupakan algoritma berbasis margin yang bertujuan untuk menemukan batas pemisah optimal antar kelas sehingga mampu menghasilkan performa klasifikasi yang baik, terutama pada data dengan dimensi yang cukup tinggi. Proses pemodelan dilakukan dengan melatih masing-masing algoritma menggunakan data latih yang telah dipersiapkan, kemudian model yang dihasilkan digunakan untuk melakukan prediksi pada data uji guna mengevaluasi kemampuan setiap algoritma dalam mengklasifikasikan status obesitas. Pembahasan lebih lanjut mengenai karakteristik dan mekanisme kerja dari masing-masing algoritma akan dijelaskan pada subbab berikutnya.

2.5 Decision Tree Classifier

Pohon (tree) adalah sebuah struktur data yang terdiri dari simpul (node) dan rusuk (edge). Simpul pada sebuah pohon dibedakan menjadi tiga, yaitu simpul akar (root/node), simpul percabangan/internal (branch/internal node) dan simpul daun (leaf node) [13]. Decision Tree akan mencari solusi permasalahan dengan menjadikan kriteria sebagai node yang saling berhubungan membentuk seperti struktur pohon [14].

2.6 Random Forest Classifier

Random Forest adalah suatu metode klasifikasi yang terdiri dari kumpulan terstruktur pohon keputusan dimana vektor acak independen didistribusikan secara identik [15]. Random Forest memiliki beberapa kelebihan, yaitu dapat meningkatkan hasil akurasi jika terdapat data yang hilang, dan untuk resisting outliers, serta efisien untuk penyimpanan sebuah data. Selain itu, Random Forest mempunyai proses seleksi fitur dimana mampu mengambil fitur terbaik sehingga dapat meningkatkan performa terhadap model klasifikasi [16].

2.7 Support Vector Classifier

Support Vector Classifier (SVC) adalah kemampuannya menangani data yang tidak bisa dipisahkan secara linear di ruang asal [17]. Kemampuan SVC menemukan Hyperplane (bidang pemisah) yang optimal. SVC tidak hanya sekadar membuat garis pemisah, tetapi mencari garis yang memiliki jarak (margin) paling jauh dari titik data terdekat di setiap kelas [18].

2.8 Evaluasi Model

Setelah proses pemodelan selesai dilakukan, tahap berikutnya adalah mengevaluasi performa model untuk melihat seberapa baik hasil prediksi yang dihasilkan. Evaluasi ini dilakukan dengan menggunakan beberapa metrik penilaian, yaitu akurasi, presisi, recall, F1-Score, support, serta Area Under the Curve (AUC). Penggunaan berbagai metrik tersebut bertujuan untuk memberikan gambaran yang lebih menyeluruh mengenai kemampuan model dalam melakukan klasifikasi. Dengan adanya evaluasi ini, kinerja model dapat dianalisis secara lebih detail, terutama dalam menilai ketepatan prediksi pada kondisi data yang memiliki distribusi kelas yang tidak seimbang.

3. HASIL DAN PEMBAHASAN


Berdasarkan analisis distribusi data, ditemukan fenomena unik di mana kategori Underweight mendominasi dataset dengan frekuensi tertinggi dibandingkan kategori Obese. Ketidakseimbangan distribusi kelas ini mencerminkan variabilitas kondisi fisik dalam populasi sampel yang digunakan, namun di sisi lain memberikan tantangan tersendiri bagi model machine learning untuk mempelajari karakteristik kelas minoritas (Obese) secara mendalam. Meskipun demikian, penggunaan algoritma berbasis tree seperti Random Forest tetap mampu mempertahankan performa tinggi karena kemampuannya dalam menangani data yang tidak seimbang tanpa kehilangan sensitivitas terhadap kategori yang jumlahnya lebih sedikit.

3.1 Analisis Eksplorasi Data

Analisis eksplorasi data (Exploratory Data Analysis/EDA) dilakukan untuk memahami pola, struktur, dan karakteristik data obesitas yang digunakan dalam penelitian. Tahap ini bertujuan untuk memberikan gambaran awal mengenai distribusi data, khususnya pada variabel target berupa status obesitas, serta hubungan antar variabel yang terdapat dalam dataset. Melalui visualisasi distribusi target, dapat dilihat perbandingan jumlah data pada setiap kategori status obesitas sehingga kondisi persebaran kelas dapat dipahami dengan lebih jelas. Selain itu, analisis hubungan antar variabel juga dilakukan menggunakan korelasi yang divisualisasikan dalam bentuk heatmap. Analisis ini digunakan untuk mengidentifikasi keterkaitan antar fitur, seperti usia, berat badan, tinggi badan, indeks massa tubuh (BMI), serta faktor lain yang berpengaruh terhadap status obesitas.

3.2 Distribusi Target

Distribusi target pada dataset klasifikasi obesitas menunjukkan pembagian kategori status berat badan, yaitu Underweight, Normal Weight, Overweight, dan Obese. Visualisasi distribusi target pada Gambar 3 menampilkan proporsi masing-masing kategori menggunakan barplot, sehingga memudahkan dalam mengidentifikasi sebaran dan potensi ketidakseimbangan kelas.




Gambar 3. Distribusi Target Kategori Obesitas

Berdasarkan hasil distribusi data pada Gambar 3, terlihat bahwa kelas Underweight memiliki jumlah kategori paling besar yaitu di kisaran 47 orang, diikuti oleh kategori Normal Weight dengan 29 orang, serta kelas Overweight yang berjumlah 20 orang. Sementara itu, kategori Obese memiliki jumlah data paling sedikit, yaitu 12 orang. Kondisi ini menunjukkan adanya ketidakseimbangan distribusi kelas pada dataset, di mana kelas Underweight lebih dominan dibandingkan kelas lainnya. Pada penelitian ini, data digunakan dalam kondisi asli tanpa dilakukan teknik penyeimbangan seperti SMOTE, sehingga distribusi target tersebut tetap dipertahankan pada proses pelatihan dan pengujian model untuk melihat kemampuan algoritma dalam menangani data dengan distribusi yang tidak seimbang.

3.1.2 Analisis Korelasi

Studi ini melakukan analisis korelasi untuk mengidentifikasi hubungan antar variabel yang berkaitan dengan kondisi obesitas, seperti usia, jenis kelamin, tinggi badan, berat badan, serta indeks massa tubuh (BMI). Analisis korelasi bertujuan untuk mengetahui apakah hubungan antar variabel bersifat positif, negatif, atau lemah, sehingga dapat membantu dalam memahami faktor-faktor yang berpotensi memengaruhi tingkat obesitas serta mendukung proses pemilihan fitur dalam pembangunan model prediksi.



Gambar 4. Korelasi Terhadap Obesitas

Gambar 4 menampilkan matriks korelasi antar variabel pada dataset obesitas, di mana intensitas warna menunjukkan kekuatan hubungan dengan rentang nilai antara -1 hingga 1. Berdasarkan hasil visualisasi

tersebut, variabel yang memiliki korelasi positif tertinggi terhadap berat badan (*Weight*) adalah *BMI* sebesar 0.97, diikuti oleh usia (*Age*) sebesar 0.47 dan tinggi badan (*Height*) sebesar 0.43. Temuan ini menunjukkan bahwa individu dengan nilai indeks massa tubuh yang tinggi, usia yang lebih tua, atau postur tubuh yang lebih tinggi cenderung memiliki berat badan yang lebih besar dalam dataset ini.


Sebaliknya, variabel *BMI* dan *Weight* menunjukkan korelasi negatif yang cukup kuat terhadap *Label_encoded* masing-masing sebesar -0.59 dan -0.57, yang mengindikasikan bahwa peningkatan pada kedua variabel tersebut berkaitan erat dengan perubahan kategori pada label obesitas yang telah di-encode. Sementara itu, variabel lain seperti jenis kelamin (*Gender*) memiliki korelasi yang sangat rendah sehingga kontribusinya terhadap perubahan variabel fisik lainnya relatif kecil. Secara keseluruhan, hasil analisis korelasi ini membantu mengidentifikasi fitur-fitur penting yang dapat dipertimbangkan dalam membangun model prediksi obesitas.

3.2 Hasil dan Evaluasi Model

Dalam penelitian ini, disajikan hasil dan penilaian dari model yang digunakan untuk memprediksi tingkat obesitas. Evaluasi dilakukan menggunakan beberapa metrik penting, seperti *Confusion Matrix*, kurva *Receiver Operating Characteristic* (ROC), serta analisis perbandingan yang mencakup akurasi, presisi, *recall*, *F1-Score*, *support*, dan AUC. Kurva ROC digunakan untuk menilai kemampuan model dalam membedakan antara kategori status berat badan dan tingkat obesitas yang berbeda, sementara analisis komparasi dilakukan untuk membandingkan performa masing-masing model yang diterapkan, seperti), Decision Tree, Random Forest, & Support Vector Classifier (SVC). Melalui hasil evaluasi ini, diharapkan dapat diperoleh pemahaman yang jelas mengenai model yang memiliki performa paling optimal dalam memprediksi status obesitas berdasarkan fitur fisik yang tersedia.

3.2.1 Confusion Matrix

Pada tahap evaluasi model, *Confusion Matrix* dari tiga algoritma *machine learning* Decision Tree, Random Forest, dan SVC digunakan untuk menilai kinerja prediksi secara detail, dengan merangkum jumlah prediksi benar (*True Positive/Negative*) dan salah (*False Positive/Negative*) untuk setiap kategori obesitas.



Gambar 5. Confusion Matrix


Secara keseluruhan, Random Forest menunjukkan performa yang paling optimal dan sempurna dalam dataset ini, dengan berhasil mengklasifikasikan seluruh data uji secara tepat pada kategori 0, 1, 2, dan 3 tanpa adanya kesalahan klasifikasi (*zero False Positives and False Negatives*). Hal ini menunjukkan akurasi yang sangat tinggi dalam mengidentifikasi setiap tingkatan obesitas. Di sisi lain, Decision Tree

menunjukkan performa yang hampir serupa namun terdapat 1 kesalahan pada kategori label 2 yang terprediksi sebagai label 0, yang mengindikasikan sedikit celah dalam stabilitas klasifikasinya.

Terakhir, SVC (Support Vector Classifier) menampilkan performa yang paling rendah di antara ketiganya. Meskipun sangat akurat pada kategori label 3 (10 data benar), model ini mengalami beberapa kesalahan klasifikasi yang signifikan pada kategori label 0 dan label 2, di mana beberapa data terprediksi secara salah ke kategori lain. Perbedaan kinerja ini menyoroti keunggulan spesifik masing-masing model, di mana Random Forest menonjol dalam akurasi umum yang sempurna, sementara SVC memerlukan optimasi lebih lanjut untuk menangani sebaran data pada kategori obesitas tertentu.

3.2.2 Kurva Roc

Untuk mengevaluasi kinerja model yang digunakan, dilakukan analisis menggunakan Kurva *Receiver Operating Characteristic* (ROC). Kurva ROC merupakan representasi grafis yang menggambarkan kemampuan model dalam membedakan antar kelas kategori obesitas pada berbagai nilai ambang keputusan. Nilai *Area Under the Curve* (AUC) yang dihasilkan mencerminkan tingkat akurasi dan keandalan di mana nilai AUC yang semakin mendekati 1 menunjukkan performa klasifikasi yang semakin baik. Gambar yang disajikan menampilkan perbandingan kurva ROC dari tiga model yang diuji, yaitu Decision Tree, Random Forest, dan SVC, sehingga memungkinkan identifikasi model dengan kemampuan diskriminatif paling optimal dalam memprediksi status obesitas.



Gambar 6. Kurva ROC

Berdasarkan kurva ROC yang terlihat pada gambar, model Random Forest menunjukkan hasil terbaik dengan nilai AUC tertinggi mencapai 0.99. Setelah itu, model Decision Tree dan SVC mengikuti dengan nilai AUC yang sama besar yaitu 0.96. Nilai AUC yang mendekati 1 pada semua model ini menandakan bahwa ketiga model ini sangat efektif dan andal dalam membedakan antara berbagai tingkatan kategori obesitas (misalnya, membedakan antara berat badan normal dan obesitas). Keunggulan sempurna pada model Random Forest menandakan bahwa model ensemble ini menawarkan sensitivitas dan spesifisitas yang paling seimbang dan optimal di berbagai *threshold* keputusan untuk dataset ini.

3.2.3 Analisis Komperasi

Untuk membandingkan kinerja ketiga model yang digunakan dalam prediksi obesitas, dilakukan analisis komparasi berdasarkan metrik evaluasi seperti *accuracy*, *precision*, *recall*, *F1-score*, *support*, dan *AUC*. Tabel 1 menyajikan hasil evaluasi dari model Decision Tree, Random Forest, dan SVC.

Tabel 1. Hasil Evaluasi Model

Classifier	Accuracy	Precision	Recall	F1-Score	Support	AUC
Random Forest	95,45%	96%	94%	95%	22 data	100%
Decision Tree	95,45%	96%	94%	95%	22 data	96%
SVC	81,82%	81%	79%	80%	22 data	96%

Tabel 1 menunjukkan kinerja tiga model pembelajaran mesin yang diterapkan untuk meramalkan kategori obesitas, yaitu Random Forest, Decision Tree, dan SVC. Berdasarkan tabel tersebut, model Random Forest menunjukkan performa terbaik dengan nilai AUC tertinggi sebesar 99%, serta nilai *precision* sebesar 96%, *recall* 94%, dan *F1-score* 95%. Model Decision Tree memiliki nilai akurasi yang sama yaitu 95,45%, namun dengan nilai AUC yang sedikit lebih rendah dibandingkan Random Forest, yaitu 96%. Sementara itu, model SVC memiliki performa paling rendah dengan akurasi 81,82% dan *F1-score* sebesar 80%. Berdasarkan hasil evaluasi, dapat disimpulkan bahwa model Random Forest menjadi pilihan terbaik untuk prediksi obesitas dalam penelitian ini, karena menunjukkan keseimbangan terbaik antara berbagai metrik evaluasi dan kemampuan klasifikasi yang sempurna berdasarkan nilai AUC-nya.

4. KESIMPULAN

Berdasarkan hasil pemodelan yang dilakukan, ketiga algoritma *Machine Learning* menunjukkan performa yang baik dalam memprediksi tingkat obesitas, namun terdapat perbedaan tingkat akurasi dan kemampuan deteksi antar model. Random Forest menjadi model dengan performa keseluruhan terbaik dengan akurasi 0.9545, *precision* rata-rata sebesar 0.96, serta *recall* sebesar 0.94. Model Decision Tree juga menunjukkan performa yang sangat kuat dengan nilai akurasi yang identik yaitu 0.9545, namun model Random Forest unggul mutlak dengan nilai AUC tertinggi yaitu 0,99 menandakan kemampuan sempurna dalam membedakan antar kategori berat badan (Normal, Obese, Overweight, dan Underweight). Sementara itu, SVC menghasilkan akurasi sebesar 0.8182, dengan rentang *precision* dan *recall* berada pada 0.79–0.81, menunjukkan performa yang cukup stabil namun masih di bawah model *tree-based*. Secara keseluruhan, hasil ini menunjukkan bahwa model-model *ensemble* khususnya Random Forest merupakan pilihan yang paling efektif dalam prediksi risiko obesitas, karena mampu memberikan keseimbangan terbaik antara akurasi, sensitivitas, dan kemampuan diskriminasi berdasarkan nilai AUC yang mencapai titik maksimal.

5. SARAN

Penelitian selanjutnya disarankan menggunakan dataset yang lebih besar dan beragam agar hasil prediksi lebih akurat dan mampu mewakili populasi yang lebih luas. Proses pra-pemrosesan juga dapat ditingkatkan melalui teknik penyeimbangan data serta pemilihan fitur yang lebih optimal. Selain itu, *tuning hyperparameter* dapat dilakukan dengan metode yang lebih canggih untuk memperoleh konfigurasi model yang lebih maksimal. Model lain dalam keluarga *tree-based* atau metode *ensemble* juga dapat ditambahkan sebagai pembanding. Terakhir, model terbaik dari penelitian ini dapat dikembangkan menjadi aplikasi prediksi risiko obesitas untuk mendukung tenaga medis dalam pengambilan keputusan.

6. UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih kepada semua pihak yang telah memberikan dukungan, saran, serta bantuan selama proses penyusunan penelitian ini. Apresiasi juga disampaikan kepada penyedia data dan rekan-rekan yang turut membantu dalam proses analisis hingga penelitian ini dapat diselesaikan dengan baik.

DAFTAR PUSTAKA

- [1] M. Sambo, S. Amelyani, And S. Simon, "Hubungan Sedentary Lifestyle Dengan Obesitas Pada Anak Usia Remaja Pada Masa Pandemi," *Jurnal Keperawatan Florence Nightingale*, Vol. 6, No. 2, Pp. 43–47, Dec. 2023, Doi: 10.52774/Jkfn.V6i2.120.
- [2] F. Reynaldi Valerian, M. Syarief, D. Abdul Fatah, J. Raya Telang, K. Kamal, And J. Timur, "Klasifikasi Tingkat Obesitas Menggunakan Metode Gbm Dan Confusion Matrix," 2025.
- [3] B. Felndity, D. Sahsun, S. Saiful, S. Musa, T. Lestari, And P. Studi Kesehatan, "Indonesian Journal Of Community Empowerment Upaya Pencegahan Obesitas Pada Remaja Melalui Pendidikan Kesehatan," 2025. [Online]. Available: <https://doi.org/10.62335>
- [4] H. H. Deru, K. M. Sobri, A. Alfitri, A. Leonardo, And E. Prasetyo, "Pentingnya Perilaku Pelaksana Regulasi Untuk Pencapaian Indeks Inovasi Daerah Yang Tinggi," *Publikasi Penelitian Terapan Dan Kebijakan*, Vol. 6, No. 1, Pp. 01–15, Jun. 2023, Doi: 10.46774/Pptk.V6i1.533.
- [5] "Community Service Articles."
- [6] J. Teke, M. Msiska, O. A. Adanini, E. Egbon, A. Osborne, And D. B. Olawade, "Artificial Intelligence For Obesity Management: A Review Of Applications, Opportunities, And Challenges," Nov. 01, 2025, *Elsevier Ltd*. Doi: 10.1016/J.Obmed.2025.100657.

- [7] G. Airlangga, "A Comparative Analysis Of Machine Learning Models For Obesity Prediction," *Jurnal Informatika Ekonomi Bisnis*, Pp. 7–11, Mar. 2025, Doi: 10.37034/InfEb.V7i1.1089.
- [8] R. Sankar Mondal, N. A. Bhuiyan, And L. Akter, "Applied It & Engineering Machine Learning For Chronic Disease Predictive Analysis For Early Intervention And Personalized Care," 2024, Doi: 10.25163/Engineering.2110301.
- [9] R. Gonzalez, A. Saha, C. J. V. Campbell, P. Nejat, C. Lokker, And A. P. Norgan, "Seeing The Random Forest Through The Decision Trees. Supporting Learning Health Systems From Histopathology With Machine Learning Models: Challenges And Opportunities," Dec. 01, 2024, *Elsevier B.V.* Doi: 10.1016/J.Jpi.2023.100347.
- [10] S. Pal, "A Comparative Analysis Of Machine Learning Algorithms For Predictive Analytics In Healthcare." [Online]. Available: <https://Heritageresearchjournal.Com/>
- [11] S. A. Utiahman, A. Mulawati, And M. Pratama, "Penerapan Support Vector Machine Dan Random Forest Classifier Untuk Klasifikasi Tingkat Obesitas", [Online]. Available: <https://Www.Kaggle.Com/Code/Pranita1202/Obesity->
- [12] M. I. Elim And E. Utami, "Performance Comparison Of Child Stunting Prediction Support Vector Machine Vs Random Forest With Grid Search Optimization," *Jurnal Teknik Informatika (Jutif)*, Vol. 6, No. 5, Pp. 5305–5319, Oct. 2025, Doi: 10.52436/1.Jutif.2025.6.5.5285.
- [13] A. H. Nasrullah, "Implementasi Algoritma Decision Tree Untuk Klasifikasi Produk Laris," Vol. 7, No. 2, 2021, [Online]. Available: <http://Ejournal.Fikom-Unasman.Ac.Id>
- [14] F. Yulian Pamuji, V. Puspaning Ramadhan, And R. Artikel, "Jurnal Teknologi Dan Manajemen Informatika Komparasi Algoritma Random Forest Dan Decision Tree Untuk Memprediksi Keberhasilan Immunotherapy Info Artikel Abstrak," Vol. 7, Pp. 46–50, 2021, [Online]. Available: [Http://Http://Jurnal.Unmer.Ac.Id/Index.Php/Jtmi](http://Http://Jurnal.Unmer.Ac.Id/Index.Php/Jtmi)
- [15] R. Supriyadi, W. Gata, N. Maulidah, A. Fauzi, I. Komputer, And S. Nusa Mandiri Jalan Margonda Raya No, "Penerapan Algoritma Random Forest Untuk Menentukan Kualitas Anggur Merah," Vol. 13, No. 2, Pp. 67–75, 2020, [Online]. Available: <http://Journal.Stekom.Ac.Id/Index.Php/E-Bisnis>■Page67
- [16] "928x Print) A71."
- [17] R. Syahril And D. Puspita, "Jite (Journal Of Informatics And Telecommunication Engineering) Classification Of Outstanding Students Using Support Vector Machine (Svm) Based On Data Mining," *Jite*, Vol. 9, No. 1, 2025, Doi: 10.31289/Jite.V9i1.13191.
- [18] A. S. Khanfar, F. A. Lone, And M. D. Moizuddin, "A Comprehensive Survey On Support Vector Machines For Intrusion Detection System." [Online]. Available: <http://Www.Publishingindia.Com/Ijkbcs/>